

Detekcija prevara u transakcijama

Mihajlo Klincov IN 43/2022, Aleksandar Zec IN 33/2022

I. UVOD

Detekcija finansijskih prevara predstavlja jedan od ključnih problema u oblasti mašinskog učenja sa direktnom primenom u bankarskoj industriji. Sa porastom broja elektronskih transakcija, ručna provera svake transakcije postaje nemoguća, što čini automatizovane sisteme za detekciju prevara neophodnim.

Cilj ovog projekta je izgradnja i evaluacija modela za detekciju finansijskih prevara koji simulira realan scenario primene. Ispitan je uticaj različitih grupa obeležja na performanse modela kroz ablation study, a kao finalni modeli korišćeni su LightGBM i CatBoost, algoritmi bazirani na gradijentnom pojačavanju stabala odluke, koji se pokazuju kao efikasni za ovakve probleme u industriji.

II. BAZA PODATAKA

A. STRUKTURA BAZE PODATAKA

Korišćena baza podataka je sintetički skup finansijskih transakcija koji pruža realističnu simulaciju transakcija kreditnim karticama. Baza sadrži 8.5 miliona uzoraka i 43 obeležja, a ciljna promenljiva "is_fraud" označava da li je transakcija prevara (1) ili validna (0). Manje od 2% transakcija u bazi označeno je kao prevara, što predstavlja ekstremnu neravnotežu klasa i glavni tehnički izazov ovog projekta.

B. ANALIZA KLASA

Od ukupno 8.5 miliona transakcija, svega oko 95.000 označeno je kao prevara. Ovakav disbalans znači da model koji uvek predviđa "validna transakcija" postiže tačnost od ~99%, što čini accuracy beskorisnom metrikom. Iz tog razloga, kao primarne metrike evaluacije korišćeni su PR AUC, Recall i F1 skor za klasu prevare.

III. OBRADA PODATAKA

A. OPTIMIZACIJA MEMORIJE I FORMAT PODATAKA

Originalni CSV fajl zauzimao je ~3.5GB na disku, a pri učitavanju u memoriju pandas je alocirao oko 4.5GB RAM-a koristeći podrazumevane tipove podataka. Kako bi se omogućila efikasna obrada na standardnom hardveru, primenjena je optimizacija tipova podataka pri učitavanju. Binarne kolone kao što je is_fraud konvertovane su u int8, celobrojne kolone sa ograničenim opsegom vrednosti u int16 ili int32, decimalne kolone u float32, a kolone sa malim brojem jedinstvenih vrednosti u category tip. Nakon optimizacije, memorijska upotreba smanjena je sa 4.5GB na 820MB, što predstavlja smanjenje od oko 5.5

puta. Pored toga, baza je konvertovana u Parquet format koji omogućava znatno brže učitavanje u poređenju sa CSV formatom zahvaljujući kolonarnoj organizaciji podataka i unapred definisanim tipovima. Dok se CSV fajl učitavao ~53 sek, parquet fajl je uspeo da se učitava za oko ~5 sek, što predstavlja smanjenje od oko 10.6 puta.

B. IZBOR I ELIMINACIJA OBELEŽJA

Od 43 dostupnih obeležja, deo je eliminisan pre treniranja. Lični identifikatori kao što su ssn, cc_num, first, last i acct_num su izbačeni jer ne sadrže informacije korisne za generalizaciju. Kolone trans_date i trans_time su izbačene jer su njihove informacije već kodirane u izvedenim temporalnim obeležjima. Kolona trans_time_secs je redundantna sa trans_time_hrs. Kolone city i merchant imaju previše jedinstvenih vrednosti i njihova informacija je bolje pokrivena kolonama city_pop i merchant_risk_*. Koordinate trgovca merch_lat i merch_long su iskorišćene za izračunavanje udaljenosti pa su zatim izbačene.


Poseban slučaj predstavlja obeležje category. Analizom stope prevare po kategoriji kroz različite vremenske periode, uočena je drastična vremenska promena, kategorije koje su u trening periodu imale 100% stopu prevare, u test periodu imale su stopu blisku 0%, i obrnuto. Ova greška sintetičkog generatora podataka činio je category štetnim obeležjem koje je aktivno pogoršavalo rezultate modela, te je eliminisano iz svih grupa obeležja.

C. ANALIZA OBELEŽJA

Analiza pojedinih obeležja sprovedena je kako bi se uočile razlike između prevarantskih i validnih transakcija, i kako bi se motivisao izbor grupa obeležja.

Distribucija iznosa transakcija pokazuje da prevare imaju uži i specifičniji opseg vrednosti u poređenju sa validnim transakcijama. Validne transakcije imaju znatno širu raspodelu iznosa, dok su prevarantske transakcije koncentrisane u određenom opsegu, što čini iznos (amt) jednim od najinformativnijih pojedinačnih obeležja i opravdava njegov izbor kao osnovno obeležje.

Analiza stope prevare po satu (Sl. 1.) otkriva da prevare nisu ravnomerno raspoređene tokom dana. Uočava se povećana stopa prevara u određenim satima, što ukazuje da prevaranti biraju specifično doba dana za aktivnost. Ovo opravdava uključivanje temporalnih obeležja kao što su trans_time_hrs i trans_time_is_night u analizu.



Slika 1. Analiza stope prevare po satu

Poređenje stope prevare između radnih dana i vikenda pokazuje da postoji razlika u učestalosti prevara u zavisnosti od dana u sedmici, što dodatno potvrđuje korisnost temporalnih obeležja.

D. PODELA PODATAKA

Podaci su podeljeni vremenskim razdvajanjem korišćenjem `unix_time` obeležja, bez nasumičnog mešanja, na tri uzastopna segmenta: trening skup (60%), validacioni skup (20%) i test skup (20%). Ovakva podela simulira realan scenario u kom model uvek trenira na istorijskim podacima i predviđa buduće transakcije. Nasumična podela bila bi neadekvatna jer bi dozvolila modelu da "vidi" buduće obrasce tokom treniranja. Stopa prevare je konzistentna kroz sve skupove: 1.09% u trening, 1.04% u validacionom i 1.22% u test skupu, što potvrđuje da vremenski split nije narušio reprezentativnost skupova.

IV. FEATURE ENGINEERING I GRUPE OBELEŽJA

A. IZVEDENA OBELEŽJA

Pored postojećih obeležja, dodata su tri nova izvedena obeležja pre podele podataka.

Udaljenost između korisnika i trgovca (`distance_km`) izračunata je primenom Haversine formule nad geografskim koordinatama korisnika i trgovca. Intuicija je da transakcija na lokaciji daleko od uobičajenog mesta boravka korisnika može biti indikator prevare. Nakon izračunavanja, koordinate trgovca (`merch_lat`, `merch_long`) su eliminisane kao redundantne.

Odnos trenutnog iznosa prema prosečnoj potrošnji korisnika u poslednjih 7 i 30 dana (`amt_vs_avg_7d`, `amt_vs_avg_30d`) kodira odstupanje od tipičnog ponašanja korisnika. Različiti korisnici imaju različite proseke potrošnje, pa sama vrednost iznosa transakcije ne govori dovoljno, važno je koliko je ta transakcija različita u odnosu na uobičajenu potrošnju tog konkretnog korisnika.

B. GRUPE OBELEŽJA

Kako bi se ispitao doprinos pojedinih grupa obeležja, obeležja su organizovana u sledeće tematske grupe: demografija korisnika (`gender`, `city_pop`, `job`), geografija

(`lat`, `long`, `distance_km`, `state`, `zip`), temporalna obeležja (`trans_time_hrs`, `trans_time_is_night`, `trans_time_day`, `trans_date_is_weekend`), ponašanje korisnika (`customer_num_trans_*`, `customer_avg_amount_*`, `amt_vs_avg_7d`, `amt_vs_avg_30d`), profil trgovca (`merchant_num_trans_*`) i rizičnost trgovca (`merchant_risk_*`).

V. KLASIFIKATORI

Za rešavanje problema detekcije prevara korišćena su dva klasifikatora bazirana na gradijentnom pojačavanju stabala odluke: LightGBM i CatBoost. Oba algoritma spadaju u grupu ensemble metoda koje iterativno grade niz stabala odluke, pri čemu svako novo stablo ispravlja greške prethodnog.

A. LIGHTGBM

LightGBM koristi strategiju rasta stabla po listu (leaf-wise), što znači da u svakoj iteraciji pronalazi list koji donosi najveće smanjenje greške i deli ga. Ovakav pristup omogućava brže učenje kompleksnih obrazaca u poređenju sa klasičnim level-wise pristupom, ali zahteva pažljiviju regularizaciju kako bi se izbeglo preprilagođavanje. Zbog ograničenja GPU implementacije koja podržava maksimalno 63 bina po obeležju, LightGBM je treniran na CPU-u koristeći sve dostupne procesorske niti.

Za LightGBM model postavljen je maksimalan broj stabala na 2000, pri čemu early stopping mehanizam prekida treniranje ukoliko se PR AUC na validacionom skupu ne poboljša u toku 100 uzastopnih iteracija. Korak učenja je postavljen na 0.05, što predstavlja umeren balans između brzine konvergencije i kvaliteta naučenih obrazaca. Kompleksnost stabla kontrolisana je parametrima `num_leaves=63` i `max_depth=6` s obzirom da LightGBM koristi leaf-wise rast, broj listova od 63 je ekvivalent dubine 6 kod klasičnih level-wise algoritama.

Disbalans klasa kompenzovan je parametrom `is_unbalance=True` koji automatski izračunava odgovarajuće težine na osnovu distribucije klasa u trening skupu. Kao kriterijum za early stopping korišćen je `average_precision`, što odgovara PR AUC metrici.

B. CATBOOST

CatBoost koristi simetričan level-wise rast stabla, što znači da se svaki nivo stabla deli uniformno. Ovakav pristup je konzervativniji od LightGBM-a, otporniji je na preprilagođavanje i posebno je dizajniran za efikasno rukovanje kategorijskim obeležjima kroz interni target encoding.

Za CatBoost model postavljen je maksimalan broj stabala na 2000, pri čemu early stopping mehanizam prekida treniranje ukoliko se PR AUC na validacionom skupu ne poboljša u toku 100 uzastopnih iteracija. Korak učenja je postavljen na 0.05, što predstavlja umeren balans

između brzine konvergencije i kvaliteta naučenih obrazaca. Dubina stabla ograničena je na 6, čime se kontroliše kompleksnost modela. Disbalans klasa rešen je eksplicitnim dodeljivanjem težine fraud klasi kroz `class_weights` parametar, gde je težina postavljena na odnos broja negativnih i pozitivnih uzoraka. Kao kriterijum za early stopping korišćen je PRAUC, što je konzistentno sa primarnom metrikom evaluacije korišćenom tokom poređenja modela. Model je treniran na procesoru koristeći sve dostupne procesorske niti (`thread_count=-1`).

VI. REZULTATI

A. POREĐENJE MODELA

Na osnovu ablation studije, kao finalni modeli odabrani su CatBoost treniran na kombinaciji `all_bez_merchant_risk` i LightGBM treniran na kombinaciji `baseline+customer`. Tabela 1. prikazuje performanse oba finalna modela na test skupu.

Model	PR AUC	ROC AUC	F1	Recall	Precision
CatBoost	0.556	0.967	0.566	0.633	0.512
LightGBM	0.487	0.961	0.542	0.590	0.502

Tabela 1. Performanse najboljeg CatBoost i najboljeg LightGBM modela


B. ZAŠTO JE CATBOOST BOLJI OD LIGHTGBM

Razlika u performansama može se objasniti arhitekturnim razlikama između dva algoritma. CatBoost koristi simetričan level-wise rast stabla koji je konzervativniji i otporniji na preprilagođavanje na velikom broju uzoraka. LightGBM koristi agresivniji leaf-wise pristup koji brže uči, ali na datasetu sa 5 miliona uzoraka i relativno čistim signalom u obeležjima ponašanja korisnika, CatBoost-ov konzervativniji pristup daje stabilnije i bolje generalizovane rezultate.

C. ANALIZA UTICAJA OBELEŽJA

Uticaji obeležja finalnog CatBoost modela prikazana je na Sl. 2. Iznos transakcije (`amt`) dominira sa oko 82% ukupne važnosti, što je konzistentno sa EDA analizom koja je pokazala jasnu razliku u distribuciji iznosa između prevare i validnih transakcija. Na drugom mestu nalazi se populacija grada (`city_pop`) sa oko 5%, što je verovatno greška sintetičkog generatora podataka. Izvedena obeležja `amt_vs_avg_7d` i `amt_vs_avg_30d` zajedno doprinose oko


5%, što potvrđuje korisnost kodiranja odstupanja od tipičnog ponašanja korisnika. Prisustvo `gender` obeležja sa oko 2% važnosti takođe se može pripisati greški sintetičkog dataseta, u realnom sistemu pol korisnika ne bi trebalo da bude informativan prediktor prevare.



Slika 2. Uticaji obeležja

D. MATRICA KONFUZIJE

Matrica konfuzije finalnog modela prikazana je na Sl. 3. Model tačno klasifikuje 99.4% validnih transakcija, dok hvata 63.3% pravih prevara. Od svih transakcija koje model označi kao prevaru, 51.2% su zaista prevare. U kontekstu detekcija prevare, propuštanje prave prevare (lažno negativan) generalno ima veće posledice od lažnog alarma (lažno pozitivan), pa je postignut recall od 63.3% prioritetniji pokazatelj od precision-a.




Slika 3. Matrica konfuzije za najbolji model


E. PR I ROC KRIVA

PR kriva i ROC kriva finalnog modela prikazane su na Sl. 4 i Sl. 5. ROC kriva pokazuje odličnu sposobnost razdvajanja klasa sa AUC od 0.967, međutim PR kriva je informativnija za ovaj problem, površina ispod PR krive od 0.556 predstavlja značajno poboljšanje u odnosu na

nasumični klasifikator čiji bi PR AUC bio jednak učestalosti klase prevare od oko 0.02.



Slika 4. PR kriva najboljeg modela



Slika 5. ROC kriva najboljeg modela

VII. ZAKLJUČAK

Glavni zaključak projekta je da obeležja koja kodiraju odstupanje od uobičajenog ponašanja korisnika daju najveći doprinos detekciji prevara. Kombinacije koje uključuju grupu `customer_behavior` - broj transakcija i prosečni iznosi u poslednjih 1, 7 i 30 dana, kao i izvedena obeležja `amt_vs_avg_7d` i `amt_vs_avg_30d` konzistentno se nalaze u vrhu rezultata bez obzira na model. Ovo je intuitivan nalaz koji je konzistentan sa realnošću, prevaranti se otkrivaju jer se njihovo ponašanje razlikuje od uobičajenih obrazaca korisnika.

A. OGRANIČENJA PROJEKTA

Projekat ima nekoliko važnih ograničenja koja treba imati na umu pri interpretaciji rezultata. Pre svega, korišćen je sintetički dataset koji ne reprezentuje kompleksnost realnih finansijskih prevara. Ovo se jasno

manifestovalo kroz obeležje `category` koje je imalo drastičnu vremensku promenu između trening i test perioda, u realnom datasetu ovakva greška ne bi bila prisutna. Dominacija obeležja `amt` sa oko 82% uticaja, kao i prisustvo `gender` i `city_pop` kao uticajnih obeležja, dodatno ukazuju na greške sintetičkog generatora podataka koji možda ne odgovaraju realnim obrascima prevara. Pored toga, hiperparametri modela nisu optimizovani pomoću algoritama već su korišćene podrazumevane vrednosti sa ručnim podešavanjem, što ostavlja prostor za poboljšanje performansi.

B. MOGUĆA POBOLJŠANJA

Najznačajnije poboljšanje bi predstavljalo testiranje na realnom datasetu finansijskih transakcija, što bi eliminisalo nedostatke sintetičkog generatora i dalo pouzdaniju procenu performansi. Sistematsko podešavanje hiperparametara kroz Grid Search moglo bi dodatno poboljšati rezultate, posebno za LightGBM koji je pokazao osetljivost na izbor hiperparametara. Pored korišćenih modela, u budućim istraživanjima moglo bi se ispitati i korišćenje XGBoost algoritma kao treće varijante gradijentnog pojačavanja, kao i neuronskih mreža koje su pokazale dobre rezultate u detekciji prevare problemima u industriji.